Aprendizaje supervisado con R

Francisco Charte

En esta sesión nos ocuparemos de:

- Fundamentos sobre aprendizaje supervisado
  - Paquetes para aprendizaje supervisado en R
  - Particionamiento de datos
  - Evaluación del rendimiento
- Ejercicios prácticos
  - Máquinas de vectores soporte
  - Boosting, Bagging, Random forest
  - Deep learning

Fundamentos sobre aprendizaje supervisado en R

Paquetes para aprendizaje supervisado en R

Paquetes para aprendizaje supervisado en R

- CRAN Task View: Machine Learning
  `cran.r-project.org/web/views/MachineLearning.html`
  - Paquetes por tipo de modelo
  - 80+ paquetes en la actualidad
  - Implementaciones heterogéneas

- Paquetes que nos interesan
  - `e1071`: Máquinas de vectores soporte
  - `neuralnet`: Redes neuronales
  - `gbm`: Boosting
  - `randomForest`: Random forest
  - `h2o`, `SAENET`: Deep learning

Paquetes para aprendizaje supervisado en R

- El paquete `caret`
  - Particionamiento, preprocesamiento y validación
  - Interfaz común para entrenamiento y predicción
  - Procedimiento homogéneo de evaluación
  - Uso desde línea de comandos (reproducibilidad)

- El paquete `rattle`
  - Interfaz gráfica de usuario
  - Carga y exploración de datos
  - Funciones de preprocesamiento y aprendizaje
  - Facilidad de uso sin línea de comandos

Fundamentos sobre aprendizaje supervisado en R

Particionamiento de datos

Particionamiento de datos - básico

- Primeras n muestras para entrenamiento, resto para test

```
nTraining <- as.integer(nrow(iris) * .75)

particion <- list(
   training = iris[1:nTraining, ],
   test     = iris[(nTraining+1):nrow(iris), ])

particion$training # Muestras de entrenamiento
particion$test     # Muestras de test
```

- Muestreo aleatorio

```
set.seed(4242)
indices <- sample(1:nrow(iris), nTraining)

particion <- list(
    training = iris[indices, ],
    test     = iris[-indices, ])
```

Particionamiento de datos - caret

- Muestreo estratificado

```
library(caret)
indices <- createDataPartition(
          iris$Species, p = .75, list = FALSE)

particion <- list(
   training = iris[indices,],
   test     = iris[-indices, ])
```

- Creación de múltiples *folds* para validación cruzada

```
folds <- createFolds(iris$Species, k = 10)

particion <- lapply(folds, function(indices)
     list(training = iris[-indices, ],
          test = iris[indices, ]))

# Muestras de entrenamiento del cuarto fold
particion$Folds04$training
```

Entrenamiento del modelo - caret

- La función **`train()`** entrena el modelo haciendo las evaluaciones que se indiquen sobre datos de training:

```
library(caret)

# 10 validación cruzada
train10CV <- trainControl(method = "cv",
                          number = 10)

# 5 validación cruzada con 2 repeticiones
train2x5  <- trainControl(method = "repeatedcv",
                          number = 5, repeats = 2)

# Uso de la configuración para entrenar
modelo <- train(formula, data = training,
          method = "classifier",
          trControl = train10CV)

names(getModelInfo()) # Lista métodos disponibles
modelLookup("modelo") # Parámetros del modelo
```

Evaluación del modelo - caret

- La función **predict()** devuelve predicciones para datos de test:

```
modelo <- train(formula, data = training,
          method = "classifier",
          trControl = train10CV)

pred <- predict(modelo, testData)
```

- Sobre el resultado devuelto por `predict()` se pueden aplicar diversas funciones:
  - `confusionMatrix(pred, testData$Clase)`
  - `sensitivity(pred, testData$Clase)`
  - `postResample(pred, testData$Clase)`
  - `multiClassSummary(pred, levels(Clase))`

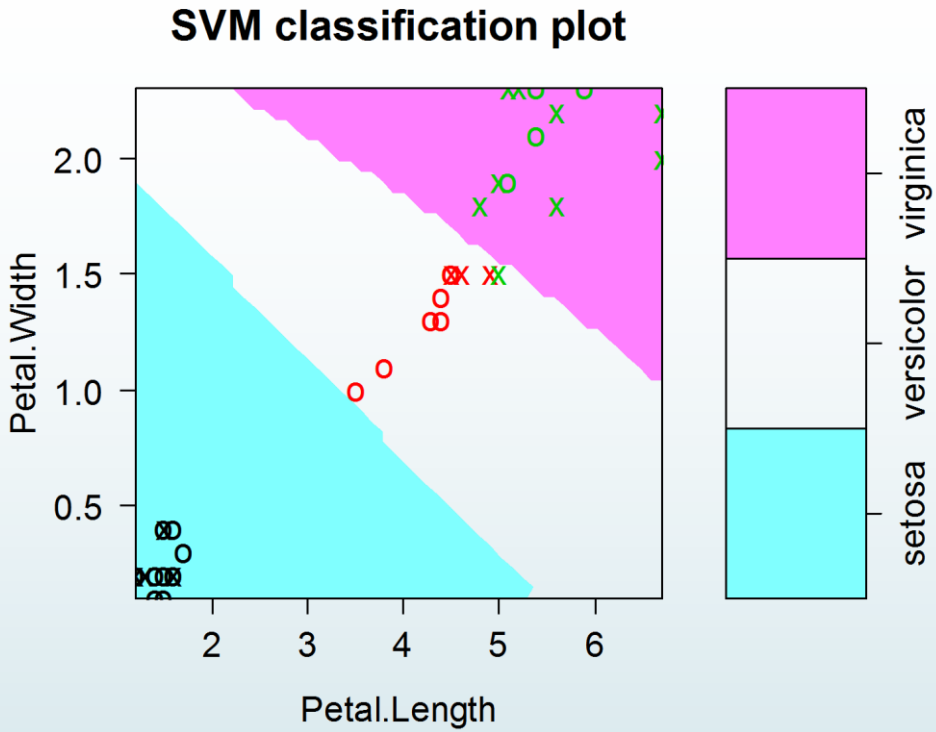

Ejercicios prácticos

Máquinas de vectores soporte

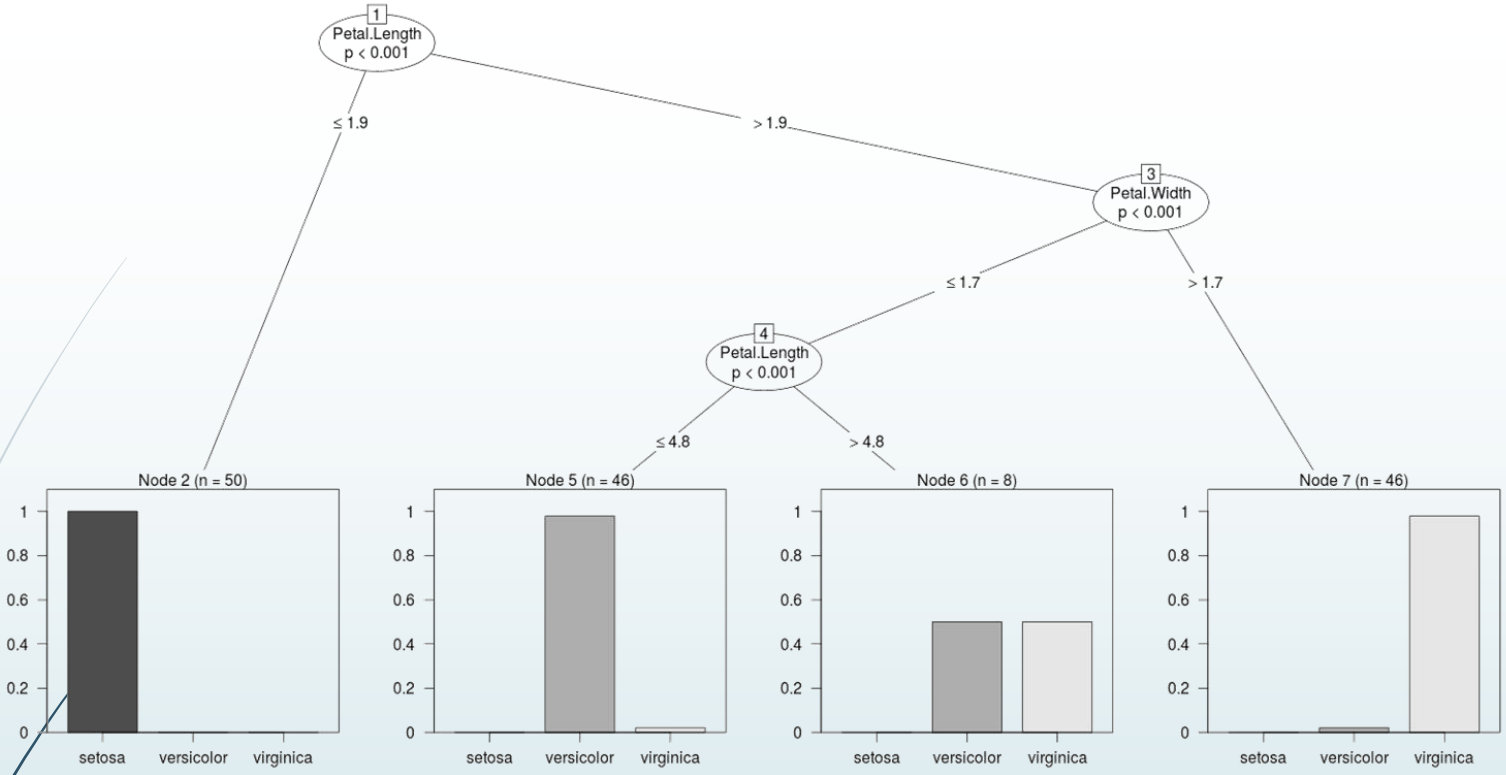

Ejercicios prácticos

Boosting, Bagging, Random forest

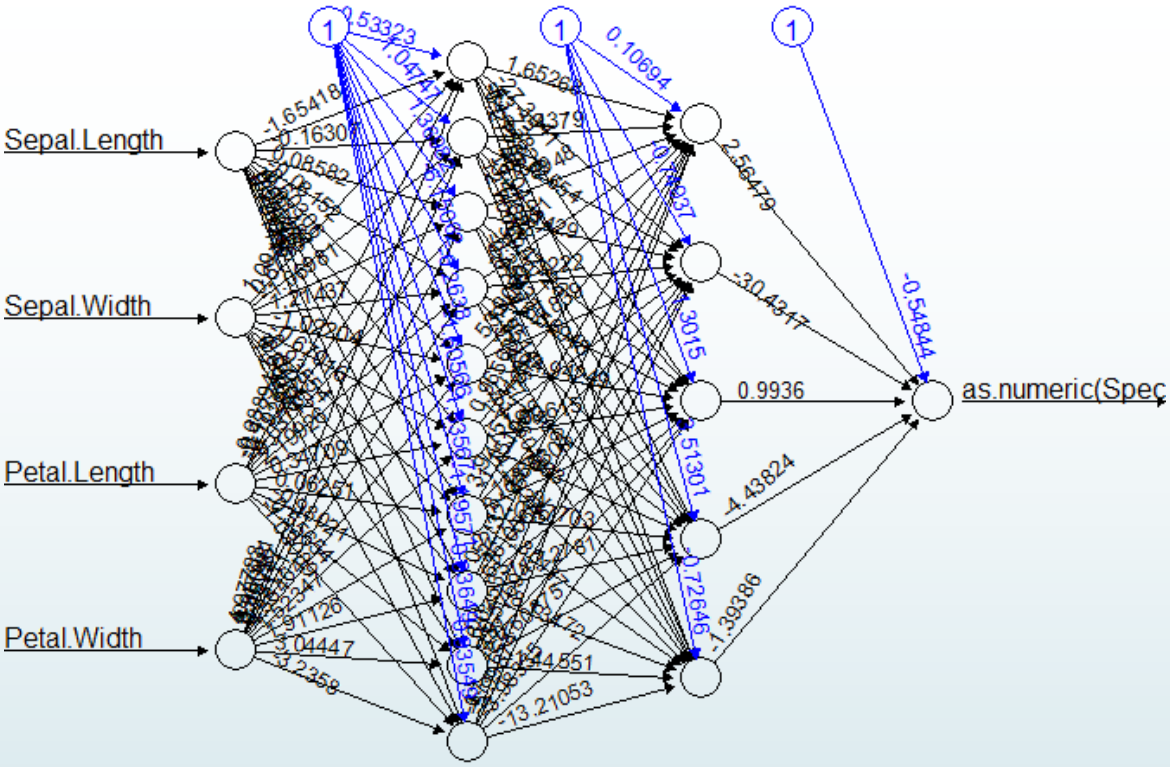

Ejercicios prácticos

Deep Learning

Aprendizaje supervisado con R

Francisco Charte